XXI Jornada Científica
Faculdades Integradas de Bauru - FIB
ISSN 2358-6044
2026

ANÁLISE DE CESTAS DE COMPRAS NO VAREJO ONLINE: COMPARAÇÃO ENTRE OS ALGORITMOS APRIORI E FP-GROWTH

Diego Rian da Silva[1]; Ana Júlia Soares de Oliveira; Arthur Pires Antunes; Gabriel Estevão dos Santos Silveira; Rafael Roberto de Jesus Ribeiro; Ronaldo Cesar Dametto[2]
[1] Aluno de Ciência da Computação – Faculdades Integradas de Bauru – FIB – diego.silva02@alunos.fibbauru.br.
[2] Professor do curso de Ciência da Computação – Faculdades Integradas de Bauru – FIB – ronaldo.dametto@fibbauru.br.

Grupo de trabalho: Ciência da Computação – Grupo 05

Palavras-chave: mineração de dados; regras de associação; Apriori; FP-Growth; varejo online.

Introdução: A mineração de regras de associação identifica produtos que tendem a ser comprados juntos e apoia decisões de venda cruzada, disposição de catálogo e promoções (AGRAWAL; IMIELINSKI; SWAMI, 1993). O algoritmo Apriori gera conjuntos candidatos nível a nível e exige várias leituras da base (AGRAWAL; SRIKANT, 1994), enquanto o FP-Growth comprime as transações em uma árvore de prefixos e dispensa a geração de candidatos (HAN; PEI; YIN, 2000). Em bases de varejo, com muitos produtos e cestas esparsas, a escolha do algoritmo e do suporte mínimo influencia diretamente o tempo de processamento e a quantidade de regras obtidas (HAN; KAMBER; PEI, 2012).

Objetivos: Desenvolver uma aplicação interativa que execute Apriori e FP-Growth sobre transações de um varejista online, permitindo ajustar suporte e confiança mínimos, comparar o tempo de execução e interpretar as regras geradas por suporte, confiança e lift, após uma análise exploratória que caracterize a base.

Relevância do Estudo: Compreender quais produtos aparecem na mesma compra vai além do ranking dos mais vendidos e pode orientar recomendações e ações comerciais em pequenos e médios varejistas. A ferramenta, de código aberto e simples de usar, também tem valor didático por permitir observar, na mesma base, o comportamento de dois algoritmos clássicos.

Material e métodos: Utilizou-se a base Online Retail, de um varejista britânico de presentes que vende pela internet, descrita por Chen, Sain e Guo (2012) e referente ao período de 01/12/2010 a 09/12/2011. Após o tratamento prévio, restaram 527.761 registros (separados por ";" e com decimal em vírgula). Cada InvoiceNo foi tratado como uma cesta, formada pelo conjunto de descrições distintas dos produtos (Description), de modo que linhas repetidas contam uma só vez. A aplicação foi escrita em Python com Streamlit e pandas. As cestas foram convertidas em matriz binária esparsa com TransactionEncoder, e Apriori e FP-Growth foram executados com a biblioteca mlxtend (RASCHKA, 2018), seguidos da extração de regras por confiança mínima. O usuário escolhe o algoritmo, o suporte (0,1% a 10%) e a confiança (10% a 100%); o tempo é medido com time.perf_counter, e as regras são exibidas com suporte, confiança e lift. Como linha de base, calculou-se o ranking dos 10 produtos presentes em mais compras.

Resultados e discussões: A base contém 19.773 compras, 4.002 produtos distintos e 4.334 clientes identificados. A mediana é de 15 itens por compra (média de 26,1; maior cesta com 1.106 itens), e 1.500 compras (7,6%) têm um único item e, portanto, não geram regras. O Reino Unido responde por 90,5% das compras, entre 38 países. A distribuição dos produtos tem cauda longa: 1.148 aparecem em menos de 20 compras, apenas 822 atingem suporte de 1% e 300 chegam a 2%, e somente 0,65% das células da matriz compra × produto estão ocupadas. Essa esparsidade indica que suportes altos reduzem o espaço de busca, ao passo que suportes baixos ampliam muito o número de candidatos, o que tende a penalizar o Apriori, como discutem Agrawal e Srikant (1994) e Han, Pei e Yin (2000). No ranking de popularidade, lideram o WHITE HANGING HEART T-LIGHT HOLDER (11,41% das compras), o JUMBO BAG RED RETROSPOT (10,56%) e o REGENCY CAKESTAND 3 TIER (10,05%); como esses produtos populares não são necessariamente comprados juntos, a análise de regras complementa o ranking. Cerca de 24,9% das linhas não têm CustomerID, o que não afeta a análise, pois as cestas são definidas por InvoiceNo. Esses resultados concordam com o perfil de varejo com muitos atacadistas relatado por Chen, Sain e Guo (2012).

Conclusão: A aplicação reúne exploração dos dados, ranking de popularidade, execução de Apriori e FP-Growth com parâmetros ajustáveis e leitura guiada das regras, mostrando que a base é grande, esparsa e de cauda longa, o que torna a escolha do suporte mínimo decisiva. Neste resumo, a comparação de desempenho entre os algoritmos baseia-se na literatura; medições sistemáticas de tempo em diferentes suportes e a avaliação das regras por lift ficam como etapas seguintes.

Referências

AGRAWAL, R.; IMIELINSKI, T.; SWAMI, A. **Mining association rules between sets of items in large databases**. In: ACM SIGMOD INTERNATIONAL CONFERENCE ON MANAGEMENT OF DATA, 1993, Washington, D.C. Proceedings [...]. New York: ACM, 1993. p. 207-216.

AGRAWAL, R.; SRIKANT, R. **Fast algorithms for mining association rules in large databases**. In: INTERNATIONAL CONFERENCE ON VERY LARGE DATA BASES, 20., 1994, Santiago de Chile. Proceedings [...]. San Francisco: Morgan Kaufmann, 1994. p. 487-499.

CHEN, D.; SAIN, S. L.; GUO, K. **Data mining for the online retail industry: a case study of RFM model-based customer segmentation using data mining**. Journal of Database Marketing & Customer Strategy Management, v. 19, n. 3, p. 197-208, 2012. DOI: 10.1057/dbm.2012.17.

HAN, J.; KAMBER, M.; PEI, J. **Data mining: concepts and techniques**. 3. ed. Waltham: Morgan Kaufmann, 2012.

HAN, J.; PEI, J.; YIN, Y. **Mining frequent patterns without candidate generation**. In: ACM SIGMOD INTERNATIONAL CONFERENCE ON MANAGEMENT OF DATA, 2000, Dallas. Proceedings [...]. New York: ACM, 2000. p. 1-12. DOI: 10.1145/342009.335372.

RASCHKA, S. **MLxtend: providing machine learning and data science utilities and extensions to Python's scientific computing stack**. Journal of Open Source Software, v. 3, n. 24, art. 638, 2018. DOI: 10.21105/joss.00638.